
Hybrid Robust Convolutional Autoencoder for Unsupervised Anomaly

Detection of Machine Tools under Noises

Shen Yan, Haidong Shao, Yiming Xiao, Bin Liu, Jiafu Wan

Robotics and Computer-Integrated Manufacturing(22023)

vol. 79, DOI: <https://doi.org/10.1016/j.rcim.2022.102441>

Smart Factory 논문리뷰

신승준 교수님

한양대학교 산업 데이터 엔지니어링학과

석사과정 강병모

2023.05.30

Background

➤ 공작기계(Machine Tools)

✓ 제조업에 사용되는 기계를 만드는 기계

→ 금속 및 단단한 재료를 절삭 및 가공

→ 대표적인 공작기계 – 선반: 소재를 회전시켜 깎거나 파내는 가공

→ Industry 4.0에 맞춰 CNC(Computer Numerical Control) 선반을 통해 자동화 및 지능화를 향해 발전

✓ 공작 기계의 이상탐지의 중요성

→ 생산 중단으로 인한 손실 극대화 및 인명피해 초래

→ 실시간 이상탐지를 통한 경제적이고 안정적인 생산



<선반>



<CNC 선반>
HANYANG UNIVERSITY

Summary

- Motivation: 공작기계의 문제 발생으로 인한 생산 중단 및 인명피해를 방지 할 수 있는 방법은 무엇일까?
- 본 연구의 목적: 노이즈가 있는 데이터를 사용한 공작기계의 이상 탐지
→ 딥러닝 기반의 비지도 학습 Hybrid Robust Convolutional Autoencoder
- Contribution 1. 실제 CNC 공작기계에 HRCAE를 적용함으로써, **라벨링 지정 안된 데이터에서 이상 탐지 가능**
2. Parallel Convolutional Denoising Feature(PCDF)을 구축하여 **다중 센서 정보를** 통합, 데이터 분포를 더 잘 학습
3. Feature Difference Distance(FDD)를 설계, **모델의 강건성 향상**
➔ 노이즈 환경에서 공작 기계 이상 탐지에 도움이 되는 시사점 제공 가능

Why Do They Use Unsupervised Learning

- 과거 공작기계 이상 탐지 방법: 머신러닝과 지도학습 기반 딥러닝
 - ✓ 머신러닝의 한계-소규모 데이터에서만 적용 가능, 수동적으로 feature 추출
 - 일반화 가능성 제한
 - ✓ 지도학습 기반 딥러닝(LSTM, RNN, CNN, etc.)
 - 장점: feature 추출의 용이성과 End to end 방식의 편의성
 - 한계:충분한 레이블이 지정된 데이터에 의존
 - 연구실에서 레이블 데이터 획득 용이
 - ➔산업 현장 적용 한계
 - ✓ 산업 현장 데이터- 라벨링된 데이터 부족 및 사용불가
 - 다양한 노이즈가 포함(ex.전자기적 간섭, 신호 간섭 etc.)
 - 공작 기계 작동 →정상 상태
- ➔다양한 **노이즈**가 존재하는 환경에서 정상 작동 데이터를 기반으로 한 **비지도 학습 모델 개발** 공작 기계의 이상 탐지를 진행

Hybrid Robust Convolutional Autoencoder

➤ Hybrid Robust Convolutional Autoencoder(HRCAE)

- ✓ 기존 Convolutional Autoencoder의 단점을 개선한 방식

➤ Convolutional Autoencoder(CAE): 고전적인 비지도 학습 방법

- ✓ CNN의 Convolution 연산을 통한 feature 추출 & 오토 인코더의 인코더 및 디코더를 통한 비지도 feature 재구성 기능 결합

-인코더: Convolution layer-그리드 데이터에서 feature 추출

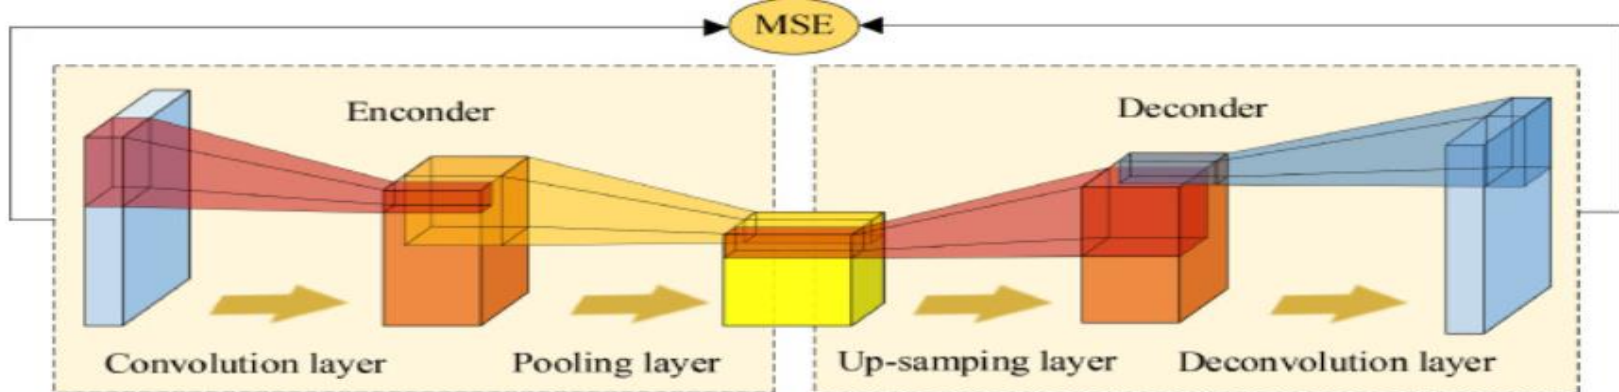

Pooling layer-입력 데이터 크기 축소 중요한 정보 추출

-디코더: Up-sampling layer-데이터 크기 확대 데이터 복원

Deconvolution layer-feature 재구성

-MSE(재구성 오류): 인코더, 디코더 데이터 축소/확대로 인한 오차 최소화

<Convolution 진행 과정>



<CAE>

HANYANG UNIVERSITY

Hybrid Residual Convolutional Autoencoder

➤ CAE의 단점 1.노이즈에 약함

→입력 데이터에 노이즈가 포함된 경우에도 재구성 시도

→노이즈가 중요한 영향을 미쳐 잘못된 결과를 초래함

➔PCDF(Parallel convolutional distribution fitting) 모듈 구성을 통해
여러 센서로 부터 다양한 정보를 획득하여 노이즈 환경에서 이상 탐지

2.정보 손실

→CAE 입력데이터 재구성 과정에서 정보 손실 발생할 수 있음

→MSE는 유클리드 거리를 통해 네트워크 최소화

-유클리드 거리: 복잡한 feature 공간의 유사성 설명하기 어려움

➔유클리드 거리와 코사인 유사도 결합 FDD(Fused directional distance)을
통해 공간적 거리와 공간적 차원 모두를 고려함

➤ PCDF와 FDD Loss function으로 구성된 HRCAE를 통해 노이즈 상황에서 공작기계의 이상 탐지

HRCAE-PCDF

➤ PCDF: 두 개 convolution network 병렬 연결 보다 많은 feature 학습

✓ CAE network와의 차이점: 1.Pooling layer와 Up-sampling 유무


→ Pooling, up-sampling 데이터 크기 축소 및 확대 과정에서 정보 손실이 발생함

➔ 노이즈가 중요한 영향력 행사할 수 있음

2.Convolution network 병렬 연결

→ 다양한 센서로부터 다양한 정보 습득

➔ 많은 feature를 학습, 노이즈로 부터 강건함

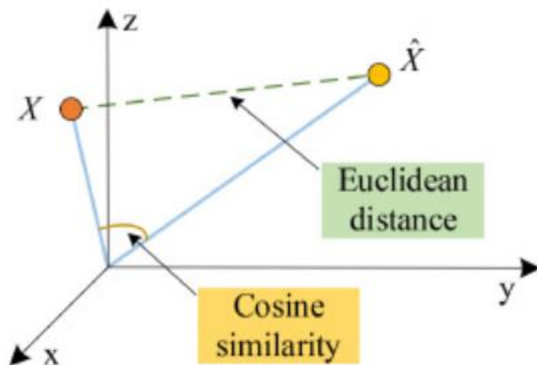


<PCDF Module>

HANYANG UNIVERSITY

HRCAE-FDD Loss Function

- FDD(Fused Directional Distance): 유클리디안 거리와 코사인 유사도 결합 손실 함수
 - ✓ Euclidean distance: 피타고라스의 정리에 기반한 두 점 사이의 거리 측정
 - 장점: 점과 점 사이의 직선거리 측정 → 직관적임
 - 단점: 복잡한 차원의 공간의 유사성을 설명하기 어려움
 - ✓ Cosine similarity: 두 점 사이의 각도 측정
 - 장점: 다차원의 공간 설명가능
 - 단점: 벡터의 방향만 맞으면 유사도가 높게 측정됨
- ➔ 유클리디안 거리의 거리 장점과 코사인 유사도의 방향 장점을 결합하여 FDD loss function을 구성
- ➔ 데이터 간의 거리 및 방향 차이 고려 정보 손실 최소화



<유클리다안 거리와 코사인 유사도의 차이>

$$MSE = \frac{1}{n} \sum_{i=1}^n (\hat{X}_i - X_i)^2$$

<MSE: 유클리디안 거리 기반 재구성 오류>

$$CS = \frac{\sum_{i=1}^n (\hat{X}_i \times X_i)}{\sqrt{\sum_{i=1}^n (\hat{X}_i)^2} \times \sqrt{\sum_{i=1}^n (X_i)^2}}$$

<Cosine Similarity, $CS \in [-1, 1]$ >

$$FDD = MSE + \lambda \frac{(1-CS)}{2}$$

<FDD loss function>

λ : 데이터 간 거리와 각도 차이의 가중치 균형 하이퍼 파라미터

Steps of HRCAE

➤ Steps of HRCAE

1.Data Preparation-Train set & Validation set: 노이즈 없는 정상 데이터

-Test set: 정상 및 이상 데이터+ 랜덤 노이즈 추가 데이터

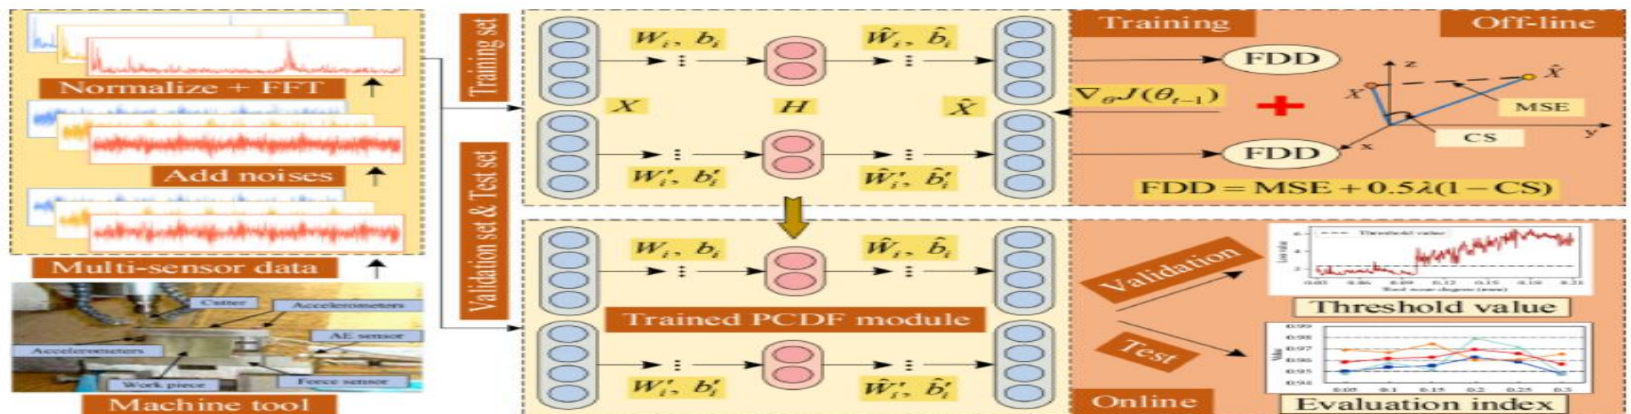
2.Model Initialization: 학습 전 가중치와 편향 초기화-가중치 계수(λ), 학습 속도(α), 반복횟수(T), PCDF 모듈 개수

-학습 파라미터 θ 로 무작위 초기화

3.Model Training: 정상 데이터만 있는 training set을 PCDF에 넣어 학습

4.Model Validation: 정상 데이터만 있는 validation set을 학습된 PCDF를 통해 검증

5.Model Test: 정상 및 이상 데이터에 noise 추가된 test set을 학습된 PCDF 모듈에 적용하여 모델 평가



<Steps of HRCAE>
HANYANG UNIVERSITY

Experimental Verifications

➤ Experiment: 고속 CNC 밀링 공작기계 부품의 이상 탐지

-밀링: 회전하는 커터를 사용하여 작업물의 표면을 절삭하는 공정

➤ Data: 기계 부품들의 마모 이미지 데이터

→ 두 개의 데이터 셋을 사용함-데이터셋 기준: 마모도 정도를 X,Y,Z로 측정하여 평균값으로 나눔

C1 데이터 셋-Train & validation set: 0.04~0.09mm 마모의 정상 데이터(각각 600개)

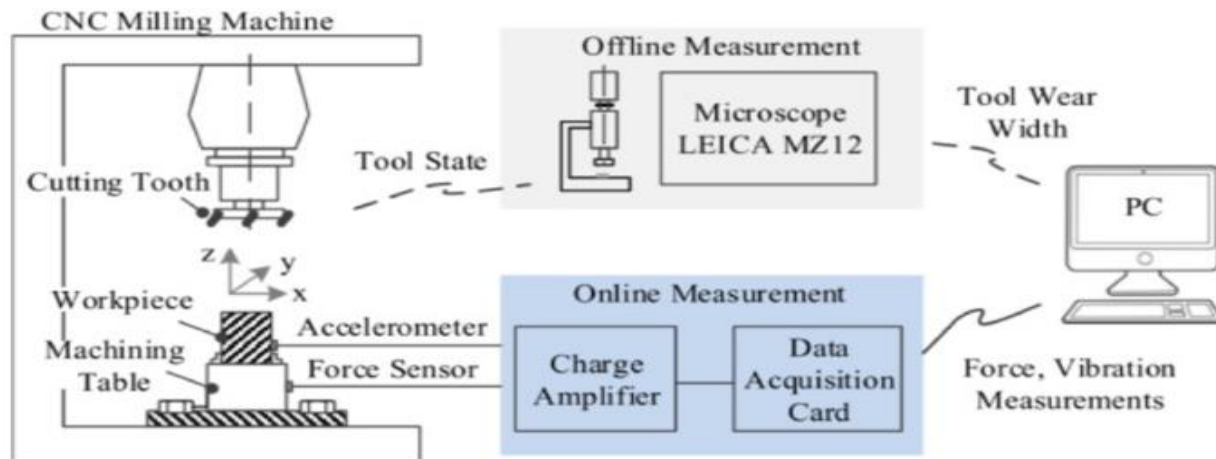
-Test set: 0.04~0.09mm 마모의 정상 데이터+0.1~0.16mm 이상 데이터(1300개)

with noise(SNR-Signal to Noise Ratio-1dB~7dB)

C4 데이터 셋-Train & validation set: 0.03~0.09mm 마모의 정상 데이터(각각 700개)

-Test set: 0.03~0.09mm 마모의 정상 데이터+0.1~0.2mm 이상 데이터(1300개)

without noise



<밀링 기계의 데이터 수집>
HANYANG UNIVERSITY

Evaluation Metrics

➤ 모델 평가 지표

- ✓ **Accuracy(정확도)** = $\frac{TP+TN}{TP+TN+FP+FN}$ TP: 이상→이상 데이터로 탐지, FP: 이상→정상 데이터로 탐지(Type-I)
FN: 정상→이상 데이터로 탐지(Type-II), TN: 정상→정상 데이터로 탐지
➔ 모델이 정상 데이터와 이상 데이터를 잘 탐지했는지 평가하는 지표

- ✓ **Precision(정밀도)** = $\frac{TP}{TP+FP}$
➔ 모델이 이상 데이터를 잘 탐지하였는지 평가하는 지표

- ✓ **Recall(재현율)** = $\frac{TP}{TP+FN}$
➔ 이상으로 분류된 데이터 중 실제 이상치가 얼마나 재현되었는지 평가하는 지표

- ✓ **F-score** = $2 * \frac{\text{Precision} * \text{Recall}}{\text{Precision} + \text{Recall}}$
➔ 정밀도와 재현율의 조화평균으로 구성

- ✓ **AUC(Area Under the Curve):** ROC(Receiver Operating Characteristic) 곡선 아래의 면적
- ROC: TP에 대한 FP의 변화를 나타냄
➔ 이진 분류 모델의 성능을 평가함
➔ 0부터 1의 값, 1에 가까울수록 모델 성능 우수

Experimental Results

➤ 실험 결과 1

- ✓ 노이즈가 있는 C1데이터-제안된 HRCAE가 정확도와 F-Score에서 좋은 결과
 - ➔ 모든 방법 중 가장 안정적이고 최적의 결과
 - 단일 컨볼루션 네트워크와 비교시 더 나은 성능
 - ➔ 병렬로 구성된 PCDF 모듈이 단일 컨볼루션 네트워크보다 더 강력한 견고성
- ✓ 노이즈가 없는 C4 데이터-제안된 HRCAE가 정확도 및 재현율, F-Score에서 좋은 결과
 - 기존의 모델에 FDD 손실 함수 추가했을 경우, 성능이 더 우수
 - ➔ FDD가 MSE보다 적은 정보 손실로 높은 성능

Unsupervised methods	Evaluation indexes (%)				Unsupervised methods	Evaluation indexes (%)			
	Accuracy	Precision	Recall	F-score		Accuracy	Precision	Recall	F-score
HRCAE	95.95 ± 0.75	96.85 ± 0.25	95.60 ± 1.50	96.21 ± 0.74	HRCAE	96.25 ± 1.17	96.01 ± 1.09	97.95 ± 2.32	96.95 ± 0.99
PCDF-MSE	94.85 ± 1.61	96.15 ± 0.98	94.20 ± 2.75	95.15 ± 1.58	PCDF-MSE	93.91 ± 2.42	96.72 ± 0.48	93.20 ± 4.15	94.89 ± 2.18
CAE-FDD	94.68 ± 1.65	96.05 ± 0.75	94.00 ± 3.59	94.89 ± 1.64	CAE-FDD	93.00 ± 2.79	95.71 ± 2.52	92.89 ± 6.85	94.10 ± 2.58
CAE-MSE	88.90 ± 4.46	92.91 ± 5.75	86.31 ± 6.56	89.29 ± 4.29	CAE-MSE	88.31 ± 5.48	96.11 ± 2.95	84.26 ± 7.84	89.67 ± 5.03
MAE-FDD	94.00 ± 1.75	96.02 ± 0.84	92.71 ± 3.63	94.30 ± 1.78	MAE-FDD	94.43 ± 1.83	96.34 ± 0.89	94.49 ± 3.31	95.38 ± 1.59
MAE-MSE	85.79 ± 3.96	90.74 ± 4.67	82.37 ± 9.15	86.03 ± 4.37	MAE-MSE	91.14 ± 4.32	95.78 ± 1.65	89.56 ± 8.49	92.35 ± 4.08
DAGMM	84.51 ± 1.56	78.35 ± 1.17	98.43 ± 2.51	87.24 ± 1.38	DAGMM	53.22 ± 2.63	97.81 ± 0.32	23.98 ± 4.32	38.37 ± 5.39
SAE-FDD	90.62 ± 6.23	96.76 ± 1.16	85.37 ± 11.35	90.41 ± 6.84	SAE-FDD	92.21 ± 1.65	96.25 ± 1.08	90.80 ± 2.55	93.43 ± 1.47
SAE-MSE	83.72 ± 10.05	90.97 ± 7.97	77.74 ± 15.67	83.19 ± 11.13	SAE-MSE	78.95 ± 8.05	95.69 ± 1.19	68.53 ± 12.91	79.37 ± 9.20
DAE-FDD	88.11 ± 8.62	97.81 ± 0.61	79.69 ± 16.25	87.03 ± 10.98	DAE-FDD	88.66 ± 6.68	95.21 ± 3.63	85.60 ± 8.54	89.90 ± 6.12
DAE-MSE	82.03 ± 11.67	95.02 ± 2.20	70.11 ± 22.15	79.23 ± 14.96	DAE-MSE	77.57 ± 8.47	94.66 ± 2.98	66.89 ± 13.39	77.87 ± 10.09

<C1 데이터 결과>

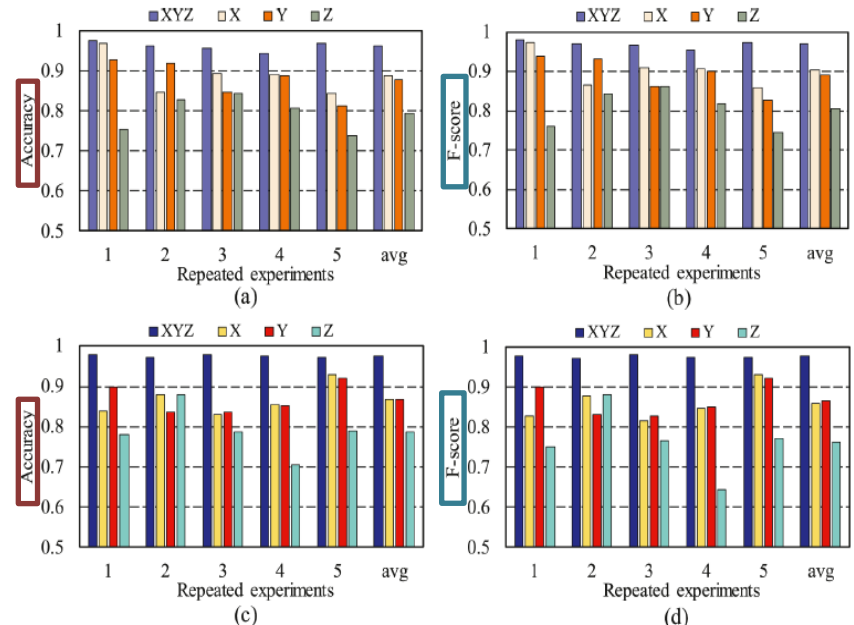

<C4 데이터 결과>

Experimental Results

➤ 실험 결과 2

- ✓ 다양한 노이즈가 존재하는 C4데이터에서의 AUC 결과-a에서 d로 갈수록 노이즈 심해짐
→ 제안된 HRCAE가 CAE보다 다양한 노이즈 상황에서 성능이 뛰어남
→ MSE를 FDD로 대체했을 때 성능이 뛰어남

- ✓ 다중센서(XYZ 방향)데이터 결과가 단일 센서보다 더 뛰어남-a,b: C4데이터, c,d: C1데이터(노이즈)
→ 실제 공장기계의 센서 위치 배치 및 선택에 대한 요구사항이 줄어듦



< C4 데이터 노이즈 정도에 따른 ROC결과 >

< C1, C4 다중 센서 단일 센서 비교 결과 >

HANYANG UNIVERSITY

Conclusion

- 공작 기계 문제 발생: 생산 중단으로 인한 손해 및 인명 피해 야기
- 과거 공작 기계 이상 탐지: 머신러닝 및 지도학습 기반 딥러닝(CAE)
 - 라벨링이 부족한 산업 현장에 적용 한계
 - 노이즈 약함
 - ➔ 병렬 컨볼루션 네트워크 PCDF와 거리와 방향을 고려한 FDD손실함수 결합
비지도 기반 HRCAE 모델 구축을 통해 노이즈 환경에서 이상 탐지
- 병렬 컨볼루션 PCDF는 단일 컨볼루션보다 노이즈에 강건함, 거리와 방향을 고려한 FDD는 MSE 보다 개선된 성능
- HRCAE 다중 센서 데이터에 좋은 성능
 - ➔실제 공작기계의 센서 위치 배치 및 선택에 대한 요구사항이 줄어들음

Further Study

➤ 모델 일반화 필요

- HRCAE의 결과는 같은 기계의 CNC 공작기계에만 유효함
- ➔ 다른 공작기계 실험을 통해 모델 성능 비교 평가 연구 필요

➤ Hyper-parameter의 조정

- 본 연구 가중치 계수(λ)를 0.05~0.3를 적용
- ➔ 0.2가 가장 좋은 성능 → 다른 실험에서는 다르게 적용될 수 있음
- ➔ 하이퍼파라미터를 연구에 맞게 자동 결정 방식 연구 → 모델 준비 어려움 감소

➤ 불규칙한 노이즈 적용 필요

- 테스트 데이터 셋에 노이즈를 추가하여 모델 평가 진행
- 포함된 노이즈는 규칙적인 진동-실제 환경 불규칙한 노이즈가 빈번하게 발생
- ➔ 불규칙 노이즈 포함하여 테스트를 진행할 필요